

# Dimension Reduction

## Principal Components Analysis

### Maximum Variance Perspective

Lemma:

样本方差矩阵:

$$S = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})(x_i - \bar{x})^T = \frac{1}{N} X^T H X$$

其中

$$H_N = I_N - \frac{1}{N} \mathbf{1}_N \mathbf{1}_N^T$$

PCA的核心思想是对原始特征空间的重构，把一组线性相关的变量通过正交变换转换成线性无关的变量，以获得最大投影方差和最小重构距离。

为了使得我们的数据均值为0，方便计算，首先我们要对数据进行中心化处理：

$$\mathbf{x}_i := \mathbf{x}_i - \bar{\mathbf{x}}$$

假设我们的投影方向是 $\vec{u}_1$  ( $|\vec{u}_1| = 1$ )，在这方向上我们有最大投影方差。我们的数据向量 $\vec{x}_i - \bar{\mathbf{x}}$ 在 $\vec{u}_1$ 上的投影可以写作：

$$|\vec{x}_i - \bar{\mathbf{x}}| \cos \theta = (\vec{x}_i - \bar{\mathbf{x}}) \cdot \vec{u}_1 = (\vec{x}_i - \bar{\mathbf{x}})^T \mathbf{u}_1$$

因此投影方差为：

$$\begin{aligned}
J(u_1) &= \frac{1}{N} \sum_{i=1}^N ((\vec{x}_i - \bar{x})^T u_1)^2 \\
&= \frac{1}{N} \sum_{i=1}^N u_1^T (\vec{x}_i - \bar{x}) (\vec{x}_i - \bar{x})^T u_1 \\
&= \frac{1}{N} u_1^T \sum_{i=1}^N (\vec{x}_i - \bar{x}) (\vec{x}_i - \bar{x})^T u_1 \\
&= u_1^T S u_1
\end{aligned}$$

于是我们的问题便转换为：

$$\begin{cases} \hat{u}_1 = \arg \max_{u_1} u_1^T S u_1 \\ u_1^T u_1 = 1 \end{cases}$$

这个优化问题可以用拉格朗日乘数法求解：

$$\begin{aligned}
\mathcal{L}(u_1, \lambda) &= u_1^T S u_1 + \lambda(1 - u_1^T u_1) \\
\frac{\partial \mathcal{L}}{\partial u_1} &= 2S u_1 - 2\lambda u_1 = 0
\end{aligned}$$

不难看出 $\lambda$ 应为方差矩阵 $S$ 的特征值， $u_1$ 为对应的特征向量。如果需要降到 $q$ 维可以取前 $q$ 个特征值和特征向量。

## Minimum Error Perspective

下面从最小重构代价方面考虑PCA，首先依然要对数据进行中心化：

$$x_i := x_i - \bar{x}$$

我们假设原来的向量可以由基底 $u_1, u_2, \dots, u_p$ 表示，即：

$$x_i = \sum_{j=1}^p (x_i^T \cdot u_j) u_j$$

如果我们要降到 $q$ 维，那么降维后数据可以表示为：

$$\hat{x}_i = \sum_{i=1}^q (x_i^T \cdot u_i) u_i$$

那么，我们的最小重构代价皆可以表示成每个数据向量之差的模的平均值：

$$\begin{aligned} J &= \frac{1}{N} \sum_{i=1}^N \|x_i - \hat{x}_i\|^2 \\ &= \frac{1}{N} \sum_{i=1}^N \left\| \sum_{j=q+1}^p (x_i^T u_j) u_j \right\|^2 \\ &= \frac{1}{N} \sum_{i=1}^N \sum_{j=q+1}^p (x_i^T u_j)^2 \\ &\triangleq \frac{1}{N} \sum_{i=1}^N \sum_{j=q+1}^p ((x_i - \hat{x}_i)^T u_j)^2 \\ &= \sum_{j=q+1}^p \left( \frac{1}{N} \sum_{i=1}^N ((x_i - \hat{x}_i)^T u_j)^2 \right) \\ &= \sum_{j=q+1}^p u_j^T S u_j \end{aligned}$$

所以

$$\begin{cases} \hat{u}_j = \arg \min_{u_j} \sum_{j=q+1}^p u_j^T S u_j \\ u_j^T u_j = 1 \end{cases}$$

由于 $u_{q+1}, u_{q+2}, \dots, u_p$ 线性无关，所以这个最优化问题我们可以分别求解,和上一节的内容一致，所以

$$\begin{aligned}
J &= \sum_{j=q+1}^p u_j^T S u_j \\
&= \sum_{j=q+1}^p u_j^T \lambda_j u_j \\
&= \sum_{j=q+1}^p \lambda_j
\end{aligned}$$

我们选取那些小的特征值及其对应的特征向量，使得  $J$  最小。

## SVD Perspective

前两节实际上都是在对样本的方差矩阵进行特征值分解：

$$S = GKG^T, G^T G = I, K = \Lambda(\lambda_1, \lambda_2, \dots, \lambda_p)$$

这一节我们从样本数据着手，首先我们对数据进行中心化：

$$\mathbf{x}_i := \mathbf{x}_i - \bar{\mathbf{x}}$$

矩阵表示即：

$$X := HX$$

然后，我们对  $HX$  进行奇异值分解：

$$HX = U\Sigma V^T$$

其中：  $U^T U = I, V^T V = VV^T = I, \Sigma \in \Lambda$

那么

$$S_{p \times p} = X^T HX = X^T H^T HX = V\Sigma U^T U\Sigma V^T = V\Sigma^2 V^T$$

又因为  $V^T V = I$ ，所以

$$\begin{cases} V = G \\ \Sigma^2 = K \end{cases}$$

同样的：

$$T_{N \times N} = H X X^T X = U \Sigma^2 U^T$$

由此我们发现，**S**,**T**有相同的特征值，我们对**S**进行特征分解可以得到方向（主成分），然后 $H X \cdot V$ 可以得到坐标；如果我们对**T**进行特征分解，我们可以直接得到坐标。（主坐标分析**PCoA**）

$$\begin{aligned} H X V &= U \Sigma V^T V = U \Sigma \\ T U \Sigma &= U \Sigma^2 U^T U \Sigma = U \Sigma \cdot \Sigma^2 \end{aligned}$$

$\Sigma^2$ 是**T**的特征值矩阵，所以 $U \Sigma$ 是**T**的特征向量矩阵，也是坐标矩阵。